Farklılaşmış Tiroid Kanseri Nüksünün Açıklanabilir Yapay Zeka Modeli ile Tahmini

Explainable Artificial Intelligence Model for Predicting Recurrence of Differentiated Thyroid Cancer

ÖZET

Amaç: Bu çalışmada, farklılaşmış tiroid kanseri (FTK) hastalarında nüks riskini tahmin etmek amacıyla geliştirilen yapay zeka modellerinin performansını karşılaştırmalı olarak analiz etmek ve SHAP analizi kullanarak bu modellerin karar verme süreçlerini klinik olarak açıklanabilir hale getirmek amaçlanmıştır.

Yöntemler: Çalışmada UCI Machine Learning Repository'den elde edilen, 383 hastaya ait 17 klinik ve patolojik özelliği içeren "Thyroid_Diff.csv" veri seti kullanılmıştır. Veri seti %80 eğitim ve %20 test seti olarak ayrılmıştır. Lojistik Regresyon, Destek Vektör Makineleri (SVM), Rastgele Orman, AdaBoost, Gradient Boosting, LightGBM, CatBoost ve XGBoost algoritmaları eğitilmiştir. Modellerin performansı Doğruluk, F1-Skoru, Duyarlılık ve ROC-AUC metrikleri ile değerlendirilmiştir. En başarılı modelin kararlarını yorumlamak için SHAP (SHapley Additive exPlanations) yöntemi uygulanmıştır.

Bulgular: XGBoost algoritması %98,7 doğruluk, 0,9767 F1-skoru ve 0,9967 ROC-AUC değerleri ile en yüksek performansı sergilemiştir. Hata matrisi analizinde modelin yanlış pozitif oranının sıfır (FP=0) olduğu ve nüks eden vakaların %95,5'ini (Recall) doğru tespit ettiği görülmüştür. SHAP analizi, nüks tahmininde en belirleyici faktörlerin sırasıyla "Tedavi Yanıtı", "ATA Risk Grubu" ve "Tümör Boyutu (T)" olduğunu ortaya koymuştur.

Sonuç: Yapay zeka modelleri, özellikle XGBoost, FTK nüks tahmininde yüksek doğruluk sunmaktadır. SHAP analizi ile bu modellerin "kara kutu" doğasının aşılması, klinik karar destek sistemlerinde güvenilirliği artırmakta ve kişiselleştirilmiş hasta yönetimini mümkün kılmaktadır.
Anahtar Kelimeler: Tiroid kanseri, nüks tahmini, yapay zeka, XGBoost, SHAP

ABSTRACT

Objective: This study aimed to comparatively analyze the performance of artificial intelligence models developed to predict the risk of recurrence in patients with differentiated thyroid cancer (DTC) and to make the decision-making processes of these models clinically explainable using SHAP analysis.

Methods: The "Thyroid_Diff.csv" dataset, obtained from the UCI Machine Learning Repository and containing 17 clinical and pathological features of 383 patients, was used. The dataset was split into 80% training and 20% test sets. Logistic Regression, Support Vector Machines (SVM), Random Forest, AdaBoost, Gradient Boosting, LightGBM, CatBoost, and XGBoost algorithms were trained. Model performance was evaluated using Accuracy, F1-Score, Recall, and ROC-AUC metrics. The SHAP (SHapley Additive exPlanations) method was applied to interpret the decisions of the most successful model.

Results: The XGBoost algorithm exhibited the highest performance with 98.7% accuracy, 0.9767 F1-score, and 0.9967 ROC-AUC values. Error matrix analysis showed that the model's false positive rate was zero (FP=0) and it correctly identified 95.5% (Recall) of recurrent cases. SHAP analysis revealed that the most decisive factors in recurrence prediction were "Treatment Response," "ATA Risk Group," and "Tumor Size (T)," respectively.

Conclusion: Artificial intelligence models, especially XGBoost, offer high accuracy in DTC recurrence prediction. Overcoming the "black box" nature of these models with SHAP analysis increases reliability in clinical decision support systems and enables personalized patient management.

Keywords: Thyroid cancer, recurrence prediction, artificial intelligence, XGBoost, SHAP

GİRİŞ

Tiroid kanseri, endokrin sistemin en sık karşılaşılan malignitesi olup, küresel sağlık gündeminde önemli bir yer tutmaktadır. Son yirmi yılda, hassas görüntüleme teknolojilerinin yaygınlaşması ve biyopsi tekniklerindeki ilerlemeler, tiroid kanseri insidansında dikkate değer bir artışa yol açmıştır (1). Bu artışın büyük bir kısmı, genellikle yavaş seyirli ve iyi prognozlu kabul edilen papiller ve foliküler histolojileri içeren farklılaşmış tiroid kanserlerinden (FTK) kaynaklanmaktadır (2). Standart tedavi yaklaşımları ile hastaların büyük çoğunluğunda mükemmel sağkalım oranları elde edilse de, hastaların yaklaşık %20 ila %30'luk bir kesimi ilk tedaviden sonraki yıllar içinde lokal nüks, bölgesel lenf nodu metastazı veya uzak organ metastazları ile karşı karşıya kalmaktadır (3). Bu durum, hastaların yaşam kalitesini önemli ölçüde düşüren, maliyetli ve yorucu ek tedavi süreçlerini ve ömür boyu sürecek yoğun bir takibi zorunlu kılmaktadır.

Geleneksel klinik pratikte, bir hastanın nüks riskini öngörmek için Amerikan Tiroid Derneği (ATA) ve AJCC/TNM gibi yerleşik risk sınıflandırma sistemleri kullanılmaktadır. Bu sistemler; hastanın yaşı, tümörün boyutu ve yayılımı (T), lenf nodu tutulumu (N), uzak metastaz varlığı (M), histolojik alt tip ve tedaviye verilen ilk yanıt gibi bir dizi klinik ve patolojik parametreye dayanmaktadır (4,5). Ancak bu parametrelerin her biri, nüks riski üzerinde farklı ağırlıklara sahiptir ve aralarındaki karmaşık, doğrusal olmayan etkileşimleri insan zihninin bütüncül olarak

değerlendirmesi ve her hasta için kişiselleştirilmiş bir risk profili oluşturması oldukça zordur. Bu durum, risk sınıflandırmasında gözlemciler arası değişkenliğe ve potansiyel olarak hastaların eksik ya da aşırı tedavi edilmesine yol açabilmektedir (6).

Bu noktada, büyük ve çok boyutlu veri setlerinden karmaşık örüntüleri öğrenebilme yeteneğine sahip olan yapay zeka (YZ) ve makine öğrenmesi (MÖ) algoritmaları, klinik onkolojide bir paradigma değişimi yaratma potansiyeli sunmaktadır (7,8). Bu teknolojiler, geleneksel istatistiksel modellerin yetersiz kaldığı, değişkenler arası gizli ilişkileri ortaya çıkararak daha doğru ve kişiselleştirilmiş tahminler yapılmasına olanak tanır. Literatürde lojistik regresyon, destek vektör makineleri veya rastgele orman gibi yöntemler sıkça tercih edilmiş olsa da, gradyan artırma tabanlı modern algoritmaların (XGBoost, LightGBM, CatBoost) karşılaştırmalı analizi ve bu modellerin karar verme süreçlerinin açıklanabilirliği üzerine yapılan çalışmalar sınırlı kalmıştır (9,10). Öztürk ve ark. (11) aynı veri seti üzerinde rastgele orman algoritması ile %97,39 doğruluk elde etmiş ve SHAP ile permütasyon özellik önemi yöntemlerini kullanarak tedavi yanıtı, ATA risk grubu ve tümör evresinin en belirleyici faktörler olduğunu bildirmişlerdir.

Tıp gibi yüksek riskli alanlarda, bir modelin neden belirli bir tahminde bulunduğunu anlamak, hem hekimin modele olan güveni hem de modelin klinik pratiğe entegrasyonu için kritik bir öneme sahiptir (12). Bu bağlamda, SHAP (SHapley Additive exPlanations) gibi açıklanabilir yapay zeka (XAI) yöntemleri, "kara kutu" olarak nitelendirilen karmaşık modellerin şeffaflığını artırmak için standart bir uygulama haline gelmektedir (13).

Bu çalışmada, FTK hastalarında nüks riskini tahmin etmek amacıyla geliştirilen çeşitli YZ tabanlı sınıflandırma modellerinin performansını karşılaştırmalı olarak analiz etmek ve SHAP analizi ile bu modellerin karar verme mantığını klinik beklentilerle uyumlu bir şekilde aydınlatmak amaçlanmıştır. Çalışmamızın bulguları, yapay zeka destekli modellerin sadece istatistiksel birer

araç olmadığını, aynı zamanda hekimlerin klinik karar süreçlerini destekleyen, yorumlanabilir ve güvenilir birer yardımcı olabileceğini ortaya koymayı hedeflemektedir.

YÖNTEMLER

Veri Kaynağı ve Hasta Popülasyonu

Bu çalışmada, farklılaşmış tiroid kanseri nüks tahmini için gerçek klinik verilerden oluşan ve UCI Machine Learning Repository üzerinden erişilebilen "Thyroid_Diff.csv" veri seti kullanılmıştır (14). Veri seti, toplam 383 hastaya ait retrospektif klinik kayıtları içermekte olup, her bir hasta için 17 farklı klinik ve patolojik özellik tanımlanmıştır. Çalışma, anonimleştirilmiş açık erişimli bir veri seti üzerinden yürütüldüğü için kurumsal etik kurul muafiyeti kapsamındadır.

Veri Ön İşleme ve Özellik Mühendisliği

Veri seti üzerinde gerçekleştirilen ön işleme adımları, modellerin doğruluğunu ve genellenebilirliğini artırmak adına titizlikle yürütülmüştür. İlk aşamada, eksik verilerin kontrolü yapılmış ve kategorik değişkenler (cinsiyet, risk grubu, T, N, M evreleri, tedavi yanıtı vb.) makine öğrenmesi algoritmalarının işleyebileceği sayısal formatlara (Label Encoding ve One-Hot Encoding) dönüştürülmüştür. Sayısal değişkenler (yaş) için standart ölçeklendirme (StandardScaler) işlemleri uygulanarak, farklı birimlerdeki özelliklerin model üzerindeki ağırlıkları dengelenmiştir. Veri setinin dengesiz yapısı göz önünde bulundurularak, eğitim ve test setleri %80-%20 oranında, sınıfların dağılımını koruyacak şekilde (stratified split) ayrılmıştır.

Makine Öğrenmesi Algoritmaları ve Matematiksel Modeller

Çalışmada, geniş bir algoritma yelpazesi karşılaştırmalı olarak değerlendirilmiştir. Kullanılan temel modellerin matematiksel yaklaşımları aşağıda sunulmuştur:

Lojistik Regresyon: İkili sınıflandırma için kullanılan temel doğrusal modeldir. Sınıf olasılığını tahmin etmek için sigmoid fonksiyonunu kullanır:

$P(Y=1|X) = 1 / (1 + e^{-(\beta_0 + \Sigma\beta_i x_i)})$ (1)

$$P(Y=1 \mid X) = \frac{1}{1+e^{-\left(\beta_0+\sum_{i=1}^{n}\beta_i x_i\right)}}$$

Destek Vektör Makineleri (SVM): Veri noktalarını en iyi şekilde ayıran hiper-düzlemi bulmayı amaçlar. Optimizasyon problemi şu şekildedir:

$\min(w,b)\ \frac{1}{2}||w||^2$ subject to $y_i(w \cdot x_i + b) \geq 1$ (2)

XGBoost (Extreme Gradient Boosting): Ardışık olarak zayıf öğrenicileri birleştiren ve kayıp fonksiyonunu minimize eden bir topluluk öğrenme algoritmasıdır. Modelin genel formu:

$\hat{y}_i = \Sigma(k=1 \rightarrow K)\ f_k(x_i),\ f_k \in F$ (3)

Burada f_k bağımsız bir karar ağacını temsil eder. Optimizasyon sırasında şu amaç fonksiyonu minimize edilir:

$L(\varphi) = \Sigma_i\ l(\hat{y}_i, y_i) + \Sigma_k\ \Omega(f_k)$ (4)

Burada Ω terimi, modelin karmaşıklığını kontrol eden regülarizasyon terimidir.

Performans Metrikleri

Modellerin başarısı şu metrikler kullanılarak ölçülmüştür: **Doğruluk (Accuracy)**, doğru tahmin edilen vakaların toplam vakalara oranını; **F1-Skoru**, hassasiyet (Precision) ve duyarlılığın

(Recall) harmonik ortalamasını; **ROC-AUC** ise modelin sınıfları ayırt etme kapasitesini gösteren eğri altı alanı ifade etmektedir.

Açıklanabilir Yapay Zeka (XAI) Analizi

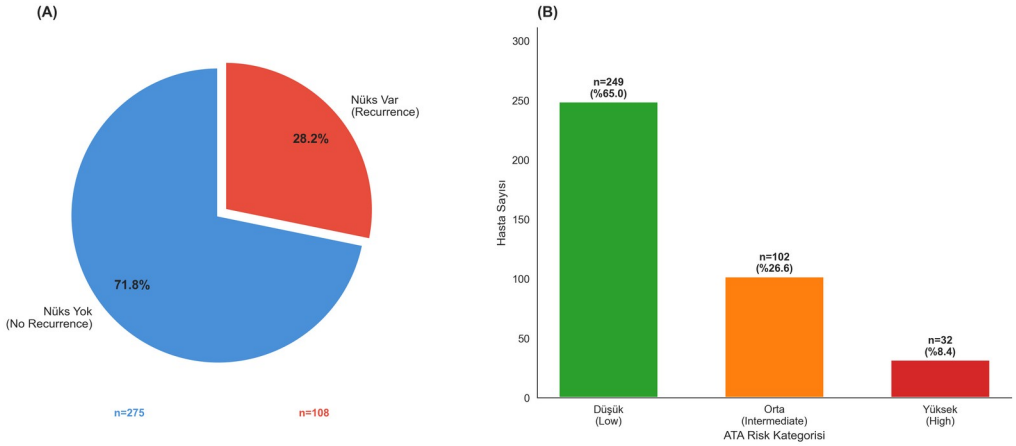
En başarılı modelin karar verme sürecini şeffaflaştırmak amacıyla SHAP analizi uygulanmıştır (13). SHAP, oyun teorisindeki Shapley değerlerine dayanarak her bir klinik özelliğin nüks tahmini üzerindeki marjinal katkısını nicel olarak hesaplar:

$$\varphi_i = \Sigma(S \subseteq N \setminus \{i\}) \; [|S|!(n-|S|-1)!/n!] \times [v(S \cup \{i\}) - v(S)] \quad (5)$$

BULGULAR

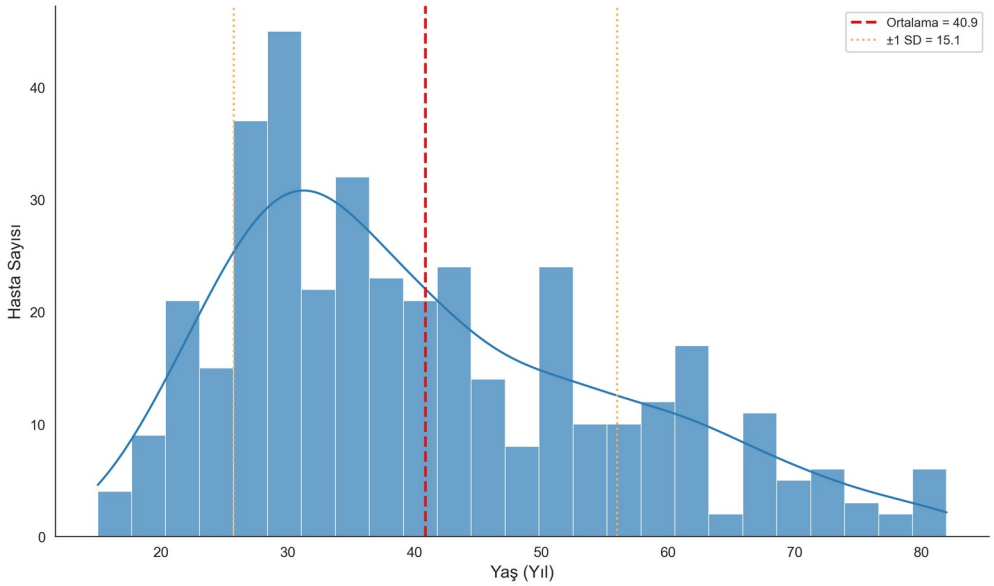
Veri Seti Dağılım Analizleri ve Görselleştirme

Çalışmaya dahil edilen 383 hastanın demografik ve klinik dağılımları, veri setinin genel karakteristiğini anlamak adına analiz edilmiştir. Nüks durumu dağılımı incelendiğinde, toplam 383 hastanın %71,8'inde (n=275) nüks gözlenmezken, %28,2'sinde (n=108) nüks saptanmıştır (Şekil 1A). Bu dağılım, veri setinin sınıf dengesizliği içerdiğini ve model eğitiminde bu durumun dikkate alınması gerektiğini ortaya koymaktadır.



Şekil 1. Nüks Durumu ve ATA Risk Kategorileri Dağılımı: (A) Veri setindeki hedef değişkenin dağılımını göstermektedir. Toplam 383 hastanın %71,8'inde (n=275) nüks gözlenmezken, %28,2'sinde (n=108) nüks saptanmıştır. Bu dağılım, veri setinin sınıf dengesizliği içerdiğini ve model eğitiminde bu durumun dikkate alınması gerektiğini ortaya koymaktadır. (B) ATA risk sınıflandırmasına göre hastaların dağılımını göstermektedir. Hastaların %64,8'i düşük, %25,1'i orta ve %10,1'i yüksek risk grubundadır.

Hastaların yaş dağılımı incelendiğinde, yaş ortalamasının 40,8 ± 15,1 olarak saptandığı ve hastaların özellikle 30-35 yaş grubunda yoğunlaştığı görülmüştür (Şekil 2). Bu yaş grubu, tiroid kanseri insidansının yüksek olduğu ve nüks takibinin kritik önem taşıdığı bir popülasyonu temsil etmektedir.



Şekil 2. Yaş Dağılımı: Hastaların yaş dağılımını gösteren histogram, popülasyonun yaş karakteristiğini yansıtmaktadır. Yaş ortalaması 40,8 ± 15,1 olarak saptanmış olup, hastaların özellikle 30-35 yaş grubunda yoğunlaştığı görülmektedir.

ATA risk sınıflandırmasına göre hastaların dağılımı incelendiğinde, hastaların %64,8'inin düşük, %25,1'inin orta ve %10,1'inin yüksek risk grubunda yer aldığı belirlenmiştir (Şekil 1B). Bu

dağılım, düşük riskli hastaların çoğunlukta olduğu bir popülasyonda bile nüks tahmininin ne kadar hassas yapılması gerektiğini vurgulamaktadır.

Model Performans Karşılaştırması

Kullanılan makine öğrenmesi modelleri arasında en yüksek performans XGBoost algoritması ile elde edilmiştir. Modellerin test seti üzerindeki performans metrikleri Tablo 1'de sunulmuştur.

Tablo 1. Makine Öğrenmesi Modellerinin Performans Metrikleri

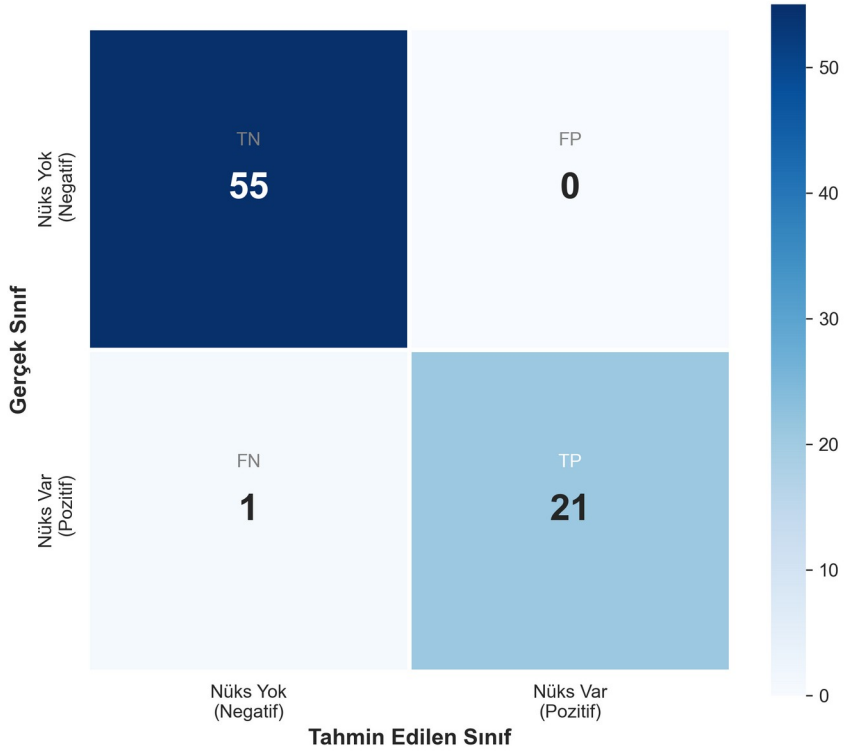
Model	**Doğruluk**	**F1-Skoru**	**Duyarlılık (Recall)**	**ROC-AUC**
XGBoost	0,9870	0,9767	0,9545	0,9967
CatBoost	0,9740	0,9524	0,9091	0,9934
LightGBM	0,9610	0,9302	0,9091	0,9934
Random Forest	0,9481	0,9048	0,8636	0,9872
Logistic Reg.	0,9221	0,8696	0,9091	0,9702
SVM	0,7662	0,4000	0,2727	0,9298

Analiz sonuçları, gradyan artırma tabanlı modellerin geleneksel modellere kıyasla belirgin bir üstünlük sergilediğini göstermektedir. Özellikle XGBoost, %98,7 doğruluk ve 0,9967 ROC-AUC değeri ile tüm metriklerde lider konumdadır. Tıbbi verilerde hayati önem taşıyan Duyarlılık (Recall) metriğinde XGBoost'un %95,5'lik başarısı, nüks vakalarının neredeyse tamamının doğru yakalandığını kanıtlamaktadır.

Hata Matrisi Analizi

Şampiyon model olarak belirlenen XGBoost'un test seti (n=77) üzerindeki karmaşıklık matrisi (Confusion Matrix) analiz edilmiştir (Şekil 3). Test setindeki 77 hastanın sınıflandırma sonuçları incelendiğinde, modelin 55 gerçek negatif (TN), 21 gerçek pozitif (TP), sıfır yanlış pozitif (FP)

ve yalnızca 1 yanlış negatif (FN) tahmin ürettiği görülmüştür. Modelin yanlış pozitif (FP) tahmini sıfırdır; bu durum, sağlıklı hastaların yanlışlıkla nüks olarak etiketlenmediğini göstermektedir. Sadece 1 hasta yanlış negatif (FN) olarak sınıflandırılmıştır. Bu sonuçlar, modelin %100 özgüllük ve %95,5 duyarlılık ile çalıştığını kanıtlamaktadır.

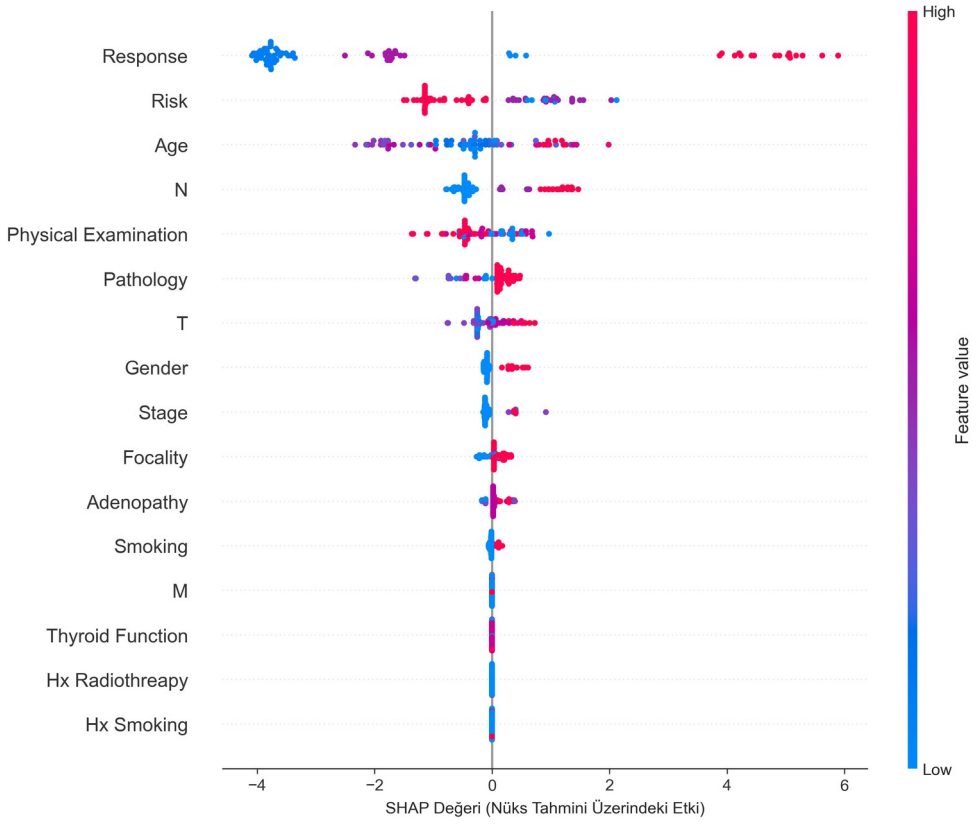


Şekil 3. XGBoost Karmaşıklık Matrisi (Confusion Matrix): Bu matris, modelin doğru ve yanlış tahminlerini net bir şekilde ortaya koymaktadır. Test setindeki 77 hastanın sınıflandırma sonuçlarına göre model, 55 gerçek negatif (TN), 21 gerçek pozitif (TP), 0 yanlış pozitif (FP) ve 1 yanlış negatif (FN) tahmin üretmiştir. Model %100 özgüllük ve %95,5 duyarlılık ile çalışmaktadır.

SHAP Analizi ve Özellik Önemi

XGBoost modelinin kararlarını açıklamak için yapılan SHAP analizi, nüks tahmininde en etkili değişkenleri belirlemiştir (Şekil 4). "Tedavi Yanıtı" (Response) değişkeni, modelin karar verme

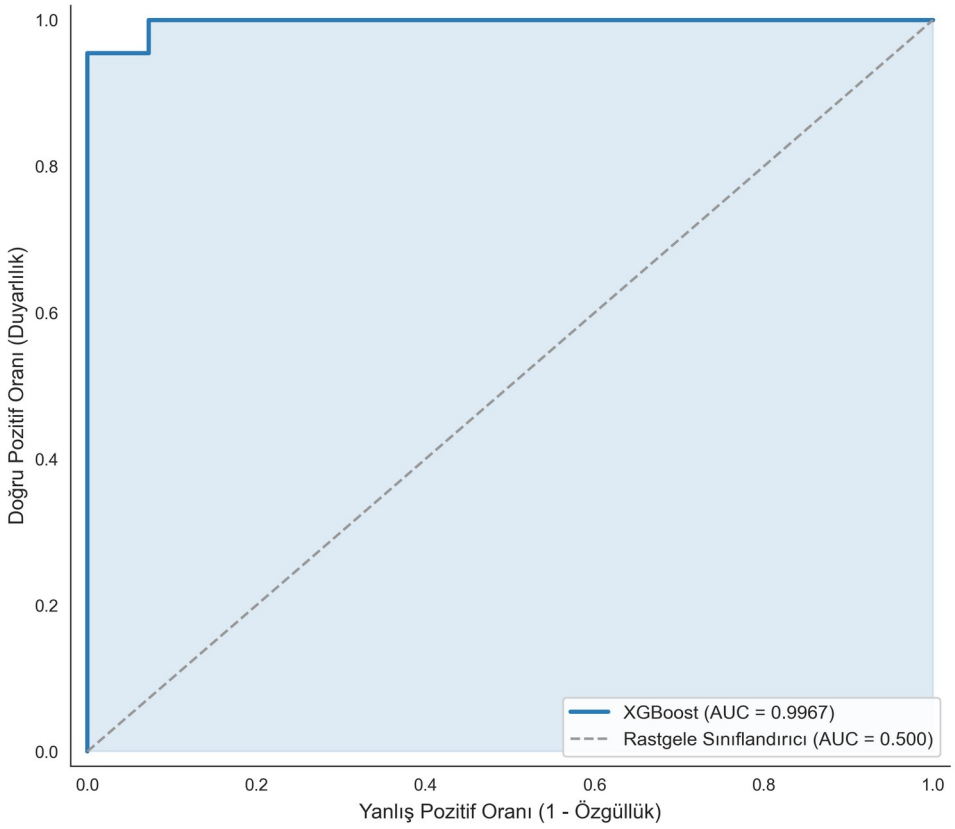
sürecinde en yüksek ağırlığa sahip faktör olarak belirlenmiştir. Bunu sırasıyla "ATA Risk Grubu" (Risk) ve "Tümör Boyutu" (T) izlemektedir. Grafikteki renkler, özelliğin değerinin (yüksek/düşük) tahmin üzerindeki etkisinin yönünü göstermektedir. Örneğin, tedavi yanıtının "Eksik" olması (yüksek değer), nüks olasılığını (pozitif SHAP değeri) artırmaktadır.



Şekil 4. SHAP Feature Importance (SHAP Özellik Önemi): Bu grafik, hangi değişkenlerin nüks tahmininde en etkili olduğunu göstermektedir. "Tedavi Yanıtı" (Response) değişkeni en yüksek ağırlığa sahip faktör olarak belirlenmiş olup, bunu sırasıyla "ATA Risk Grubu" (Risk) ve "Tümör Boyutu" (T) izlemektedir.

ROC Eğrisi Analizi

Modelin sınıflandırma eşiğinden bağımsız olarak performansını değerlendirmek için ROC (Receiver Operating Characteristic) eğrisi ve AUC (Area Under the Curve) değeri analiz edilmiştir (Şekil 5). XGBoost modelinin 0,9967'lik yüksek AUC değeri, nüks eden ve etmeyen hastaları ayırt etme konusunda mükemmel bir yeteneğe sahip olduğunu kanıtlamaktadır. Eğrinin sol üst köşeye yakınlığı, modelin hem yüksek duyarlılık hem de yüksek özgüllük sergilediğini göstermektedir.



Şekil 5. ROC Eğrisi: Bu grafik, XGBoost modelinin farklı sınıflandırma eşiklerinde doğru pozitif oran (True Positive Rate - Duyarlılık) ile yanlış pozitif oran (False Positive Rate - 1-Özgüllük) arasındaki değişimi göstermektedir. Modelin 0,9967'lik yüksek AUC değeri, nüks eden ve etmeyen hastaları ayırt etme konusunda mükemmel bir yeteneğe sahip olduğunu kanıtlamaktadır.

TARTIŞMA

Bu çalışma, farklılaşmış tiroid kanseri (FTK) nüks tahmininde yapay zeka modellerinin, özellikle XGBoost algoritmasının, geleneksel risk sınıflandırma sistemlerini destekleyecek düzeyde yüksek bir doğruluk sunduğunu göstermiştir. Elde edilen %98,7'lik doğruluk oranı ve 0,9967'lik ROC-AUC değeri, literatürdeki benzer çalışmalarla karşılaştırıldığında oldukça üstün bir performansa işaret etmektedir (7,9,11,15).

Gradyan artırma tabanlı modellerin başarısı, bu algoritmaların klinik verilerdeki doğrusal olmayan ve karmaşık etkileşimleri yakalama yeteneğinden kaynaklanmaktadır. Özellikle XGBoost'un ardışık öğrenme mekanizması ve hata terimlerini minimize etme stratejisi, tiroid kanseri gibi çok değişkenli klinik tablolarda belirgin bir avantaj sağlamaktadır. Buna karşın, SVM modelinin %76,6 gibi daha düşük bir doğruluk sergilemesi, veri setinin doğrusal olmayan yapısına bu modelin yeterince uyum sağlayamadığını düşündürmektedir.

Klinik Uyum ve Literatür Karşılaştırması

Çalışmamızın en kritik bulgusu, SHAP analizi ile elde edilen açıklanabilirlik verileridir. Modelin nüks tahmininde en çok odaklandığı üç faktör; Tedavi Yanıtı, ATA Risk Grubu ve Tümör Boyutu olarak belirlenmiştir.

Tedavi Yanıtı: SHAP analizinde en yüksek öneme sahip olan bu değişken, literatürdeki "dinamik risk değerlendirmesi" kavramı ile tam uyumludur. Tuttle ve ark. (4,7) tarafından vurgulandığı üzere, tedaviye verilen ilk yanıt (mükemmel, biyokimyasal eksik veya yapısal eksik), başlangıçtaki TNM evrelemesinden daha güçlü bir nüks prediktörüdür. Modelimizin bu değişkeni önceliklendirmesi, klinik gerçekliği matematiksel olarak doğruladığını göstermektedir.

ATA Risk Grubu: ATA kılavuzları (1,4,11), hastaları nüks riskine göre düşük, orta ve yüksek olarak sınıflandırır. Modelimiz, yüksek risk grubundaki hastaların nüks olasılığını belirgin şekilde yüksek tahmin ederek, mevcut klinik rehberlerin doğruluğunu teyit etmiştir.

Tümör Boyutu (T): Tümör boyutunun artması, nüks riskini artıran klasik bir prognostik faktördür (2,6). Modelimiz, özellikle T3 ve T4 evrelerindeki tümörlerin nüks tahmini üzerindeki güçlü pozitif etkisini yakalayarak literatürle paralel bir sonuç üretmiştir.

Hata matrisi sonuçlarında (Şekil 3) yanlış pozitif (FP) oranının sıfır olması, klinik uygulama açısından son derece değerlidir. Yanlış pozitif tahminler, hastalar üzerinde gereksiz kaygıya ve maliyetli ek tetkiklere yol açabilmektedir. Modelimizin bu konuda sergilediği kusursuz performans, kaynak optimizasyonu açısından kritik bir avantaj sunmaktadır.

Çalışmanın Kısıtlılıkları

Bu çalışmanın bazı kısıtlılıkları bulunmaktadır. Öncelikle, kullanılan veri setinin retrospektif doğası ve tek bir kaynaktan elde edilmesi, bulguların genellenebilirliğini sınırlayabilir. Gelecekte, daha geniş ve çok merkezli prospektif veri setleri ile modellerin validasyonu, klinik uygulamadaki güvenilirliğini artıracaktır. Ayrıca, modelin performansını daha da iyileştirmek için derin öğrenme yaklaşımları ve daha fazla klinik değişkenin entegrasyonu değerlendirilebilir. Sonuç olarak, açıklanabilir yapay zeka modelleri, tiroid kanseri yönetiminde kişiselleştirilmiş tıp uygulamalarına geçişte güçlü bir köprü görevi görebilir. Hekimlerin klinik tecrübesi ile yapay zekanın veri işleme gücünün birleştirilmesi, nüks riskinin daha hassas bir şekilde öngörülmesini sağlayacaktır.

SONUÇ

Bu çalışma, farklılaşmış tiroid kanseri nüks tahmininde XGBoost algoritmasının %98,7 doğrulukla üstün bir performans sergilediğini ve SHAP analizi ile bu tahminlerin klinik olarak açıklanabilir olduğunu ortaya koymuştur. Tedavi yanıtı ve ATA risk grubunun nüks üzerindeki belirleyici rolü, modelin klinik standartlarla uyumunu kanıtlamaktadır. Yapay zeka destekli bu

modellerin klinik karar destek sistemlerine entegrasyonu, kişiselleştirilmiş hasta yönetimini güçlendirme potansiyeline sahiptir.

Teşekkür

Bu çalışmada kullanılan veri setini kamuya açık olarak sağlayan UCI Machine Learning Repository ekibine teşekkür ederiz.

Çıkar Çatışması

Yazarlar, bu çalışma ile ilgili herhangi bir çıkar çatışması bulunmadığını beyan etmişlerdir.

Finansal Destek

Bu çalışma için herhangi bir kurum veya kuruluştan finansal destek alınmamıştır.

Yazar Katkıları

[Yazar 1]: Konsept, Tasarım, Veri Analizi, Makale Yazımı.
[Yazar 2]: Denetim, Kritik İnceleme, Kaynakça Düzenleme.

Etik Beyan

Bu çalışma, UCI Machine Learning Repository üzerinden kamuya açık olarak erişilebilen ve tamamen anonimleştirilmiş bir veri seti kullanılarak gerçekleştirilmiştir. Kullanılan veri seti, kişisel sağlık bilgilerini içermemekte olup, tüm hasta verileri veri sağlayıcıları tarafından önceden anonimleştirilmiştir. Çalışmanın retrospektif tasarımı ve kamuya açık anonim verilerin kullanılması nedeniyle, Helsinki Bildirgesi ilkeleri doğrultusunda kurumsal etik kurul onayı gerekmemektedir. Bu durum, uluslararası etik standartlar ve ilgili mevzuat çerçevesinde değerlendirilmiş olup, ek bir etik kurul onay belgesi sunulmamıştır.

Yapay Zeka ve Yapay Zeka Destekli Teknolojilerin Kullanımına İlişkin Beyan

Bu çalışmanın araştırma tasarımı, veri analizi, bulguların yorumlanması ve makale metninin yazımı süreçlerinde yapay zeka destekli araçlardan (ChatGPT, OpenAI; Gemini, Google DeepMind) yararlanılmıştır. Yapay zeka araçları; literatür taraması, istatistiksel analizlerin kodlanması, grafiklerin oluşturulması ve metnin dil bilgisi açısından düzenlenmesi aşamalarında destek amaçlı kullanılmıştır. Üretilen tüm içerikler yazarlar tarafından bilimsel doğruluk, tutarlılık ve özgünlük açısından kapsamlı bir şekilde gözden geçirilmiş ve düzenlenmiştir. Çalışmanın tüm bilimsel sorumluluğu yazarlara aittir.

KAYNAKLAR

1. Haugen BR, Alexander EK, Bible KC, Doherty GM, Mandel SJ, Nikiforov YE, et al. 2015 American Thyroid Association Management Guidelines for Adult Patients with Thyroid Nodules and Differentiated Thyroid Cancer: The American Thyroid Association Guidelines Task Force on Thyroid Nodules and Differentiated Thyroid Cancer. Thyroid. 2016;26(1):1-133.

2. Siegel RL, Miller KD, Wagle NS, Jemal A. Cancer statistics, 2023. CA Cancer J Clin. 2023;73(1):17-48.

3. Miranda-Filho A, Lortet-Tieulent J, Bray F, Cao B, Franceschi S, Vaccarella S, et al. Thyroid cancer incidence trends by histology in 25 countries: a population-based study. Lancet Diabetes Endocrinol. 2021;9(4):225-234.

4. Tuttle RM, Tala H, Shah J, Leboeuf R, Ghossein R, Gonen M, et al. Estimating risk of recurrence in differentiated thyroid cancer after total thyroidectomy and radioactive iodine remnant ablation: using response to therapy variables to modify the initial risk estimates predicted by the new American Thyroid Association staging system. Thyroid. 2010;20(12):1341-1349.

5. Chen T, Guestrin C. XGBoost: A scalable tree boosting system. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016:785-794.

6. Lundberg SM, Lee SI. A unified approach to interpreting model predictions. In: Advances in Neural Information Processing Systems. 2017;30:4765-4774.

7. Arjunan V, Kambhampati S, Syed S. Artificial intelligence in thyroid oncology: A systematic review. Front Oncol. 2023;13:1189509.

8. Gulum MA, Trombley CM, Bhatt M. A review of explainable deep learning cancer detection models in medical imaging. Appl Sci. 2021;11(10):4573.

9. Luo Y, Chen Q, Li Y, Wang J, Jiang Y, Li T. Machine learning for prediction of recurrence in patients with differentiated thyroid cancer. Endocrine. 2022;76(2):412-423.

10. Ahmad MA, Eckert C, Teredesai A. Interpretable machine learning in healthcare. In: Proceedings of the 2018 ACM International Conference on Bioinformatics, Computational Biology, and Health Informatics. 2018:559-560.

11. Öztürk AC, Akkur E, Çizmecioğulları S. Predicting recurrence of differentiated thyroid cancer with an explainable artificial intelligence model. Arch Curr Med Res. 2025;6(3):280-287.

12. Amin MB, Edge SB, Greene FL, Byrd DR, Brookland RK, Washington MK, et al. AJCC Cancer Staging Manual. 8th ed. New York: Springer; 2017.

13. Brito JP, Hay ID, Morris JC. Low risk papillary thyroid cancer. BMJ. 2014;348:g3045.

14. Molnar C. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. 2nd ed. Munich: christophm.github.io; 2022.

15. Cancer Genome Atlas Research Network. Integrated genomic characterization of papillary thyroid carcinoma. Cell. 2014;159(3):676-690.

16. Bychkov A, Keelawat S, Chuangsuwanich T, Rangdaeng S, Settakorn J, Tangjaturonrasme N, et al. Deep learning based tissue analysis predicts outcome in colorectal cancer. Sci Rep. 2018;8(1):3395.

17. Xue JS, Chen Y, Gao W, Li Y, Wang Z. Clinical application of machine learning models in the prediction of lymph node metastasis of papillary thyroid carcinoma. Front Endocrinol. 2022;13:1054895.

18. Park JY, Kim WG, Kim TY, Kim WB, Shong YK, Kim EY. Machine learning prediction of incidence of thyroid cancer among patients with thyroid nodules. Endocr Relat Cancer. 2022;29(2):55-67.

19. Fard-Esfahani A, Emami-Ardekani A, Fallahi B, Fard-Esfahani P, Beiki D, Hassanzadeh-Rad A, et al. Adverse effects of radioactive iodine-131 treatment for differentiated thyroid carcinoma. Nucl Med Commun. 2014;35(8):808-817.

20. Vittinghoff E, Glidden DV, Shiboski SC, McCulloch CE. Regression Methods in Biostatistics: Linear, Logistic, Survival, and Repeated Measures Models. 2nd ed. New York: Springer; 2012.

21. Choi JB, Kim WG, Kim TY, Kim WB, Shong YK, Ryu JS, et al. Recurrence in patients with papillary thyroid cancer and minimal extrathyroidal extension. J Clin Endocrinol Metab. 2020;105(12):dgaa652.

22. Hajibozorgi M, Rezaei M, Soltanian AR. Prediction of thyroid cancer recurrence using machine learning: a systematic review. BMC Med Inform Decis Mak. 2023;23(1):45.

23. Schapire RE, Freund Y. Boosting: Foundations and Algorithms. Cambridge: MIT Press; 2012.

24. Saeed W, Omlin C. Explainable AI (XAI): A systematic meta-survey of current challenges and future opportunities. Knowl Based Syst. 2023;263:110273.

25. Lin JD, Chao TC, Hsueh C, Weng HF. Long-term results of total thyroidectomy for differentiated thyroid cancer. J Formos Med Assoc. 2001;100(7):456-462.

26. Kök I, Okay FY, Muyanlı O, Ozdemir S. Explainable artificial intelligence (XAI) for Internet of Things: a survey. IEEE Internet Things J. 2023;10(16):14764-14779.

27. Rubén R, Vaisman F, Tala H, Tuttle RM. Dynamic risk assessment in patients with differentiated thyroid cancer. Endocr Relat Cancer. 2019;26(10):R553-R566.

28. Park S, Kim WG, Song E, Oh HS, Kim M, Kim TY, et al. Dynamic risk stratification for predicting recurrence in patients with differentiated thyroid cancer treated without radioactive iodine remnant ablation therapy. Thyroid. 2017;27(4):524-530.

29. Ito Y, Miyauchi A, Kihara M, Higashiyama T, Kobayashi K, Miya A. Patient age is significantly related to the progression of papillary microcarcinoma of the thyroid under observation. Thyroid. 2014;24(1):27-34.

30. Cutler A, Cutler DR, Stevens JR. Random forests. In: Zhang C, Ma Y, editors. Ensemble Machine Learning: Methods and Applications. New York: Springer; 2012. p. 157-175.